**CURSO DE CURTA DURAÇÃO - 2017** 

# BIOINFORMÁTICA

BIOME - CENTRO MULTIUSUÁRIO DE BIOINFORMÁTICA - UFRN

# NEXT GENERATION SEQUENCING

Análise de Dados de Sequenciadores de Segunda Geração



E-mail: jorge@imd.ufrn.br



RNA-seq II



Bioinformatics Multidisciplinary Environment











# **Objetivo:**

Utilizar as ferramentas básicas de transcriptoma para obter o padrão de expressões dos mirRNAs de uma amostras.

### Comandos Básicos de Linux:

Para trabalhar com nossos dados, vamos precisar saber alguns comandos básicos do Linux. Podem procurar mais informação no site:

http://wiki.ubuntu-br.org/ComandosBasicos

# Ferramentas:

- 1- Linux.
- 2- WebServer.
- 3- cutadapt
- 4- mapper
- 5- miRDeep2

# Inicial:

# Login maquina local:

Login:

Senha:

# Login no server:

ssh -p 4422 bif@10.7.5.38

Senha: bif0003

# Inicial:

#### Pasta com dados iniciais:

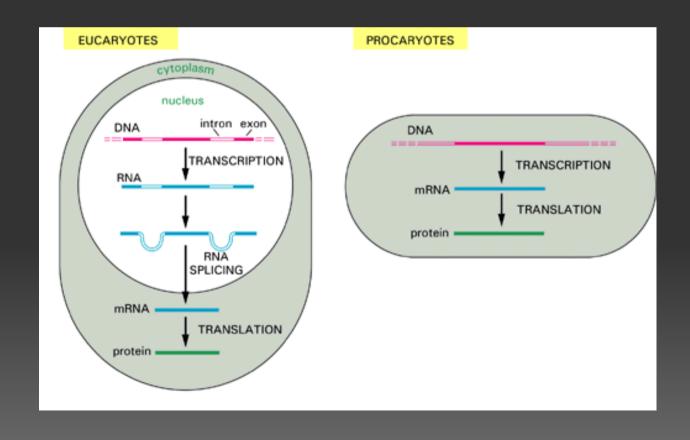
/home/treinamento/NGS/RNAseq/

#### **Pasta servidor WEB:**

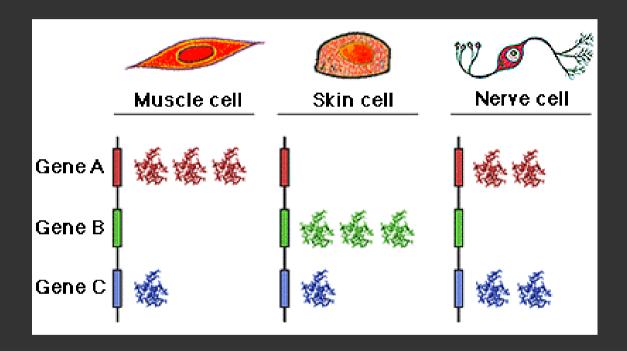
/home/bif/public\_html/

#### **Transcriptoma**

Transcriptoma: conjunto total de RNAs em uma dada célula ou tecido.



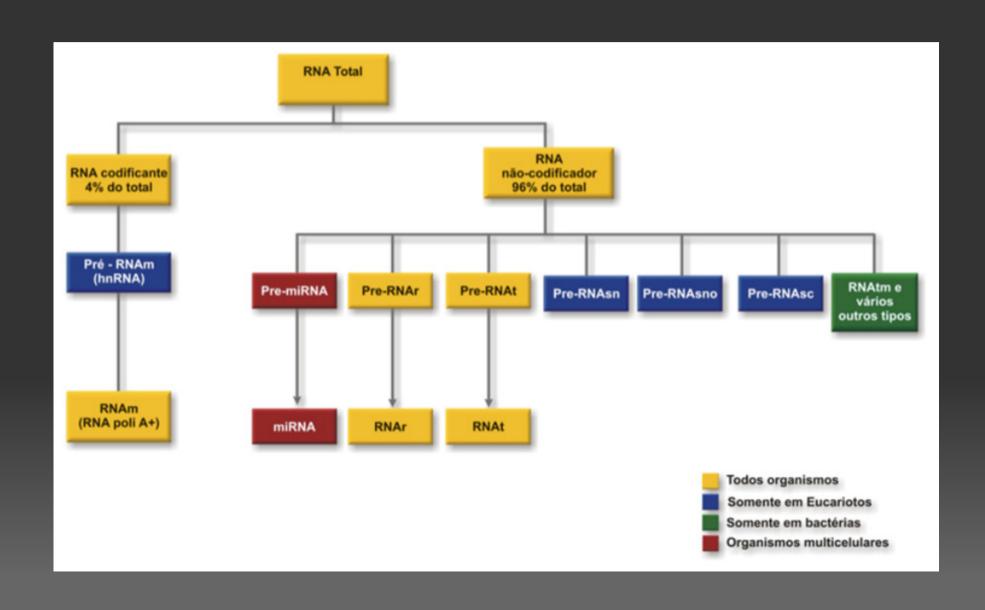
#### **Transcriptoma**



A expressão gênica diferencial é responsável pela diferenciação fenotípica entre células do mesmo organismo.



#### Transcriptoma: composição



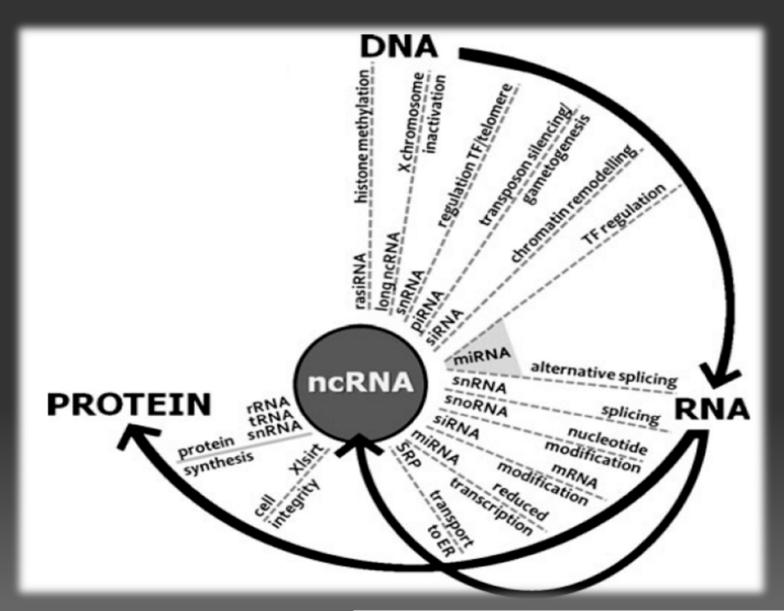
#### RNA não-codificador (ncRNA)

- Produtos de genes presentes no genoma.
- ncRNA não é traduzido para uma proteína.
- Participa nos mais diversos processos biológicos: regulação de ciclo celular, diferenciação de células e tecidos, desenvolvimento, apoptose, metabolismo.
- Presente nos diversos reinos dos seres vivos.
- A diversidade funcional de cada classe de ncRNAs ainda está longe de ser totalmente conhecida.

# ncRNAs: principais classes

Nome	Descrição	
microRNA	pequeno RNA (maduro 18-25 nt) que, em geral, contém um papel de regulação pós-transcricional.	
piRNA	piwi-interacting RNAs – relacionado às células germinativas.	
siRNA/RNAi	small interfering RNAs ou RNA de interferência – pequeno RNA (20-25 nt), que em geral, interfere na expressão de genes por silenciamento.	
snoRNA	small nucleolar RNAs, encontra no núcleo das células eucarióticas, sendo relacionado a vários processos como: modificação de RNA etc	
sRNA	Pequenos RNAs ou <i>small</i> RNA (< 200 nucleotídeo [nt]) em que se incluem os miRNA, siRNA e outros	
TERC	Componente de Telomerase RNA	
Longos ncRNAs	RNAs com mais de 200 nucleotídeos. Ex. Xist RNA	
NAT	Transcrito antisenso ou Natural antisense transcripts	
SRP RNA	Partícula de reconhecimento de sinal ou Signal Recognition Particle RNA	
Ribozymes	Rnase P, Hammerhead e RNAs intrônicos grupo I, II e III	
Promoter- associated RNAs	RNAs recentemente descritos localizados em região promotora/TSS. Ex.: pasRNA, palRNA, tiRNA, CUT, PROMPT, TSSa-RNA etc.	
Termini- associated RNAs	RNAs descritos localizados na da região terminadora de genes.	

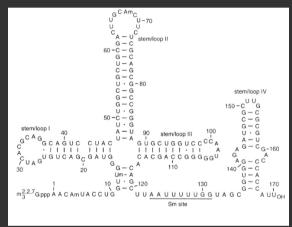
#### ncRNAs: principais classes



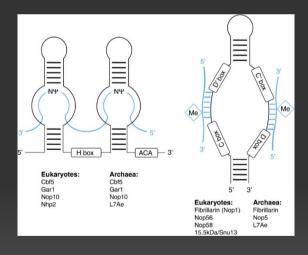
Lozada-Chávez et al., 2012; Condorelli e Dimmeler, 2008

#### ncRNAs: estrutura secundária

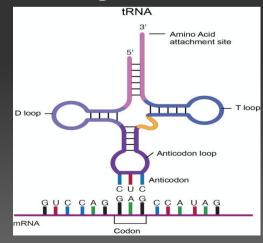
#### Pequeno RNA nuclear (snRNA)



#### Pequeno RNA nucleolar (snoRNA)



#### RNA transportador (tRNA)

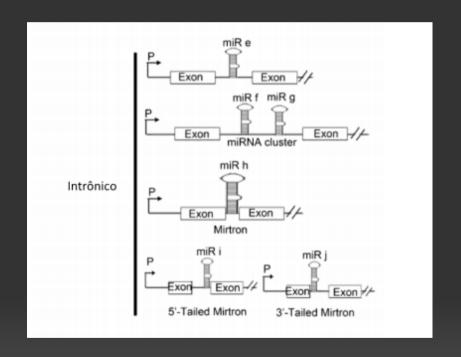


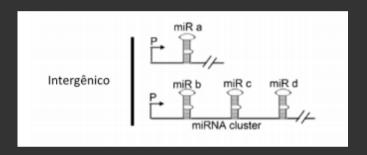
### ncRNAs: tamanho (nt)

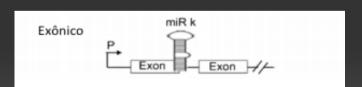
Classe de sRNAs	Tamanho (nt)	Organismos
miRNA	17-25	Plantas, algas, vírus animais, protistas
endosiRNA	21-24	Plantas, fungos, animais
exosiRNA	~24	Plantas, fungos, animais
natsiRNA	21-24	Plantas
casiRNA	24	Plantas
tasiRNA	21	Plantas
piRNA	26-31	Células germinativas
piRNA-like	24-30	Drosophila, C. elegans
rasiRNA	26-31	Plantas, animais

Classe de sRNAs	Tamanho (nt)	Organismos
tasiRNA	21	Plantas
piRNA	26-31	Células germinativas
piRNA-like	24-30	Drosophila, C. elegans
rasiRNA	26-31	Plantas, animais
tiRNAs	30-40	Leveduras,ani mais
tRFs	17-26	animais
snoRNA	60-300	Eucariotos, procariotos
snRNA	~150	Eucariotos

### ncRNAs : organização no genoma

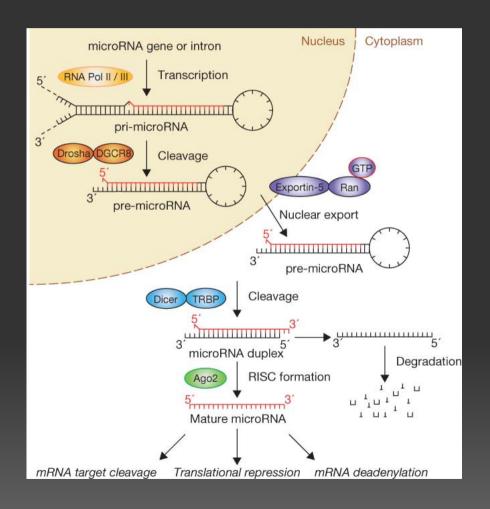






#### MicroRNA (miRNA)

- Micro RNA atua na regulação da expressão gênica de eucariotos superiores, diminuindo a expressão de seus alvos.
- Um único microRNA pode ter centenas de alvos diferentes.
- Mecanismo de complementaridade parcial com mRNAs, geralmente na região 3' UTR.



# miRNAs: diferenças entre espécies

mature miRNAs	<b>Human</b> 1100	<b>Fly</b> 186
known targets	111 (10%)	32 (17%)
pre-miRNAs	940	171
in introns	442 (47%)	60 (35%)
overlapping exons	47 (5%)	2 (1%)
overlapping UTRs	27 (3%)	7 (4%)
antisense	137 (15%)	18 (11%)
<10kb from another miRNA	297 (32%)	80 (47%)







- Quantos ncRNAs existem no genoma?
- Qual é o repertório total de estruturas e funções?
- Como as sequências de ncRNAs evoluem?
- Como podemos anotar essas sequências de ncRNAs?

#### Metodologias

## Principais abordagens

- Micro-arranjos
- Bioinformática *ab initio*: análise composicional, predição de estrutura secundária, homologia estrutural ou de sequências, sinais de promotores e terminadores.
- RNA-Seq



#### RNA-Seq: metodologia

- A metodologia central do RNA-Seq é simples:
  - Isolar o RNA alvo (mRNA ou ncRNA).
  - Fragmentar o RNA
  - Síntese do cDNA.
  - Sequenciamento.
  - Mapear as sequências no genoma.
- O maior número de vezes que um determinado transcrito for detectado, maior a sua abundância.
- Se um número grande de sequências for gerada, é obtido uma visão compreensiva e quantitativa do transcriptoma.

#### RNA-Seq: estratégias

RNA-Seq



Enriquecido com mRNAs

Enriquecido com ncRNAs

TruSeq Stranded Total RNA with Ribo-Zero Human/Mouse/Rat

TruSeq Stranded Total RNA with Ribo-Zero Gold

TruSeq Stranded Total RNA with Ribo-Zero Globin TruSeq Small RNA

#### Bancos de dados biológicos

rRNA
 5S ribosomal db, RDPII, European rRNA db

tRNA GtRDB, Sprinzl

RNase P DB

SRP SRPDB

tmRNA website, tmRNA database

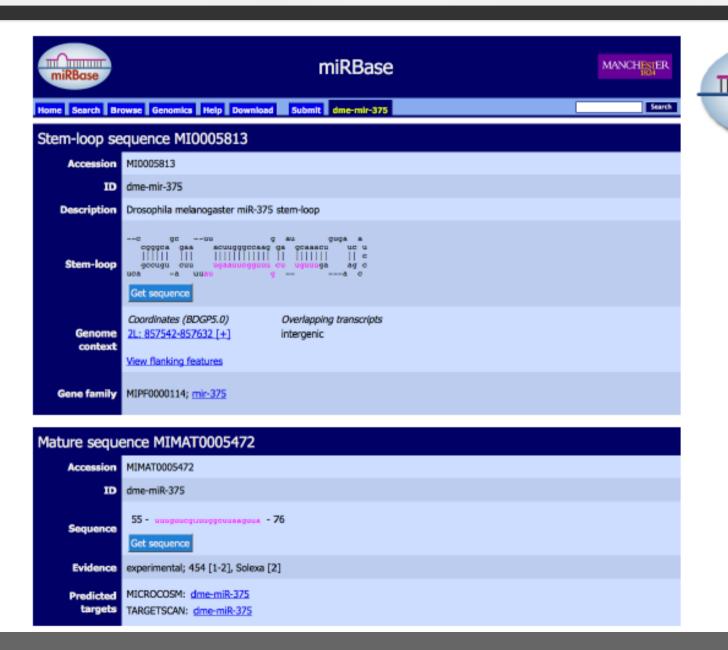
uRNAs uRNADB

snoRNAs snoRNAbase, snoRNAdb, snoopy

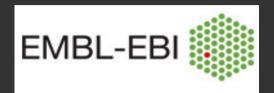
miRNAs miRBase, miRNAmap, microRNAdb



#### Bancos de dados biológicos



#### Bancos de dados biológicos



#### Rfam 11.0 (August 2012, 2208 families)

The Rfam database is a collection of RNA families, each represented by **multiple sequence alignments**, **consensus secondary structures** and **covariance models** (CMs). <u>More...</u>

QUICK LINKS YOU CAN FIND DATA IN RFAM IN VARIOUS WAYS...

SEQUENCE SEARCH Analyze your RNA sequence for Rfam matches

VIEW AN RFAM FAMILY View Rfam family annotation and alignments

VIEW AN RFAM CLAN View Rfam clan details

KEYWORD SEARCH Query Rfam by keywords

TAXONOMY SEARCH Fetch families or sequences by NCBI taxonomy

JUMP TO enter any accession or ID Go Example

Enter any type of accession or ID to jump to the page for a Rfam family, sequence or genome

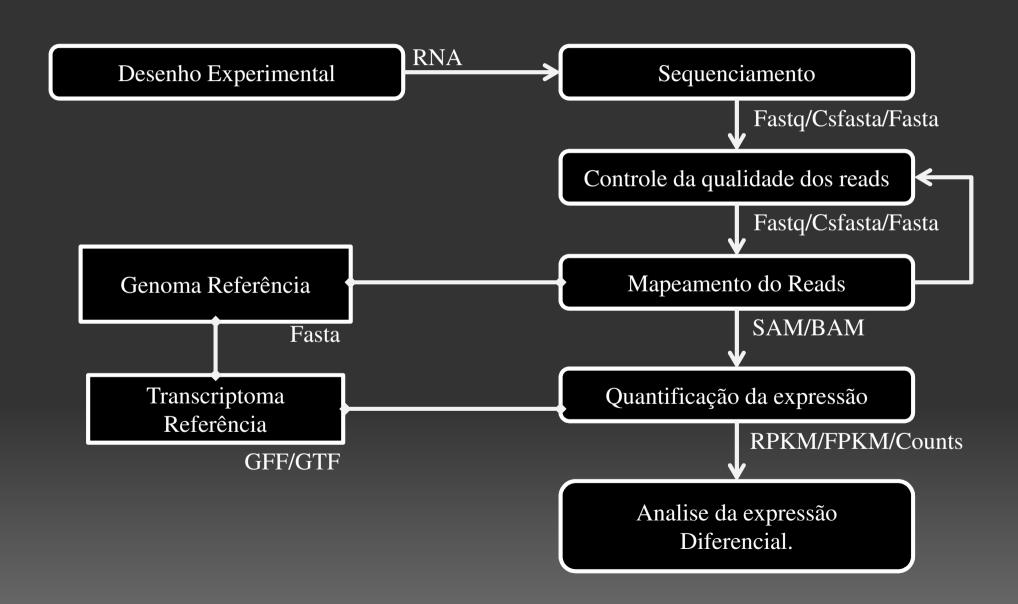




#### RNA-Seq + Bioinformática: análises

- Quantificar a expressão dos ncRNAs conhecidos.
- Identificar novos ncRNAs e sua localização no genoma.
- Quantificar expressão diferencial.
- Identificar mutações em ncRNAs.
- Anotar as sequências de ncRNA em bases biológicas.
- No caso de microRNAs, identificar os genes alvo.

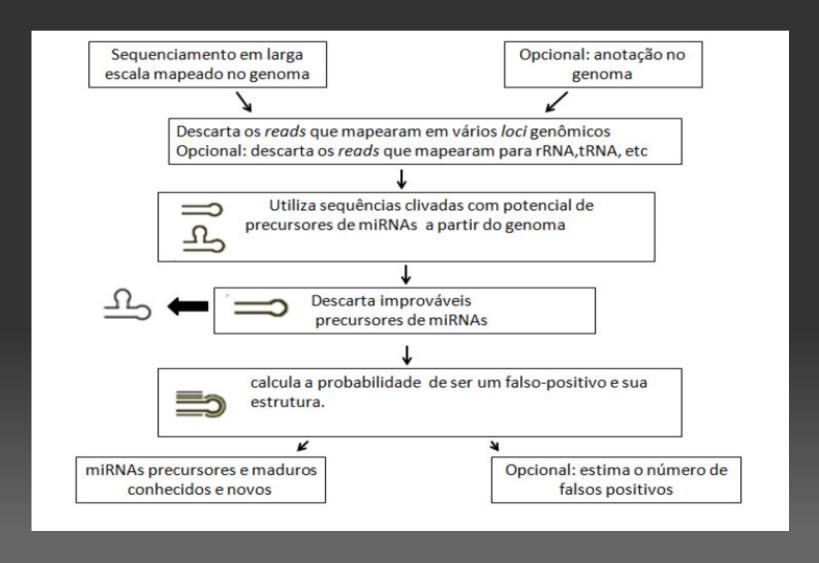
#### Fluxo de trabalho





#### Programas de Mapeamento

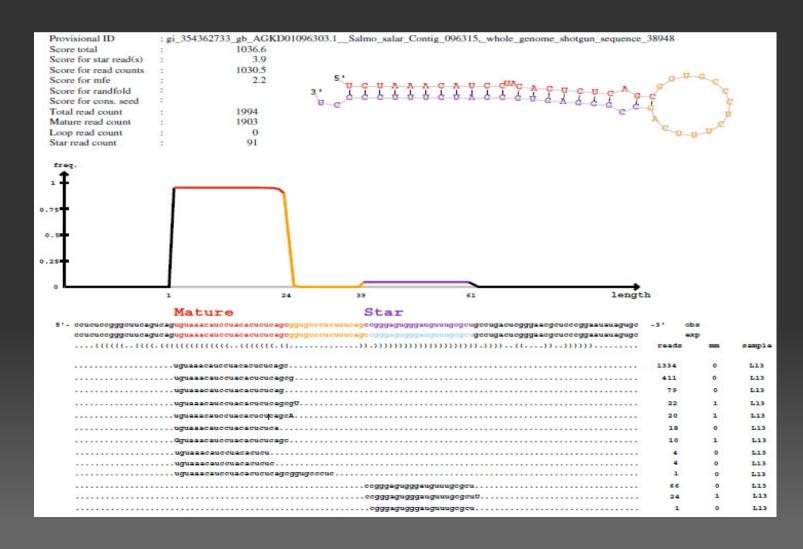
#### Para microRNAs: MirDeep2





#### Programas de Mapeamento

#### Resultado do MirDeep2



#### Programas de Mapeamento

#### Para as demais famílias de ncRNA:

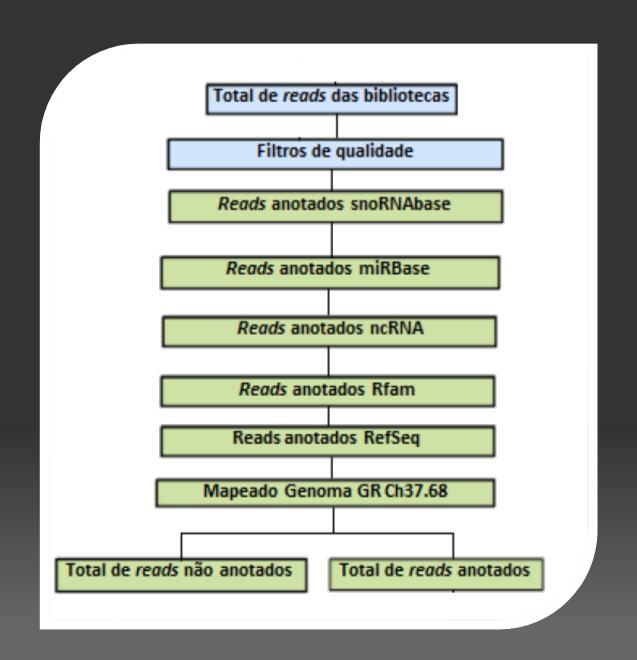


Bowtie Extremely fast, general purpose short read aligner



TopHat
Aligns RNA-Seq reads to the genome using Bowtie
Discovers splice sites

#### Busca de novos ncRNAs



#### Expressão Diferencial

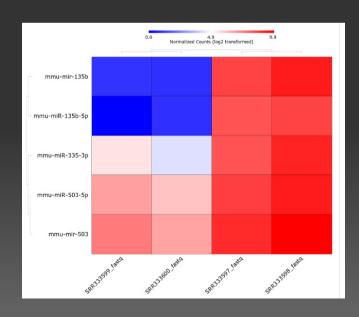
#### Resultado do MirDeep

```
hsa-let-7c-3p
                       hsa-let-7c
               17
hsa-let-7d-5p
               7719
                       hsa-let-7d
               217
                       hsa-let-7d
hsa-let-7d-3p
hsa-let-7e-5p
              2203
                       hsa-let-7e
hsa-let-7e-3p
                       hsa-let-7e
hsa-let-7f-5p
               28898
                       hsa-let-7f-1
hsa-let-7f-1-3p 265
                       hsa-let-7f-1
hsa-let-7f-5p
                       hsa-let-7f-1
               28898
hsa-let-7f-5p
                       hsa-let-7f-2
               28993
hsa-let-7f-5p
               28993
                       hsa-let-7f-2
                       hsa-let-7f-2
hsa-let-7f-2-3p 45
hsa-let-7g-5p
                       hsa-let-7g
               23244
hsa-let-7g-3p
               70
                       hsa-let-7g
hsa-let-7i-5p
              659
                       hsa-let-7i
hsa-let-7i-3p
               33
                       hsa-let-7i
hsa-miR-1
                       hsa-mir-1-1
hsa-miR-1
                79
                       hsa-mir-1-1
                       hsa-mir-1-2
hsa-miR-1
hsa-miR-1
                79
                       hsa-mir-1-2
hsa-miR-100-5p 6136
                       hsa-mir-100
hsa-miR-100-3p 1
                       hsa-mir-100
hsa-miR-101-5p 75
                       hsa-mir-101-1
hsa-miR-101-3p 7045
                       hsa-mir-101-1
hsa-miR-101-3p 7045
                       hsa-mir-101-1
hsa-miR-101-3p 7123
                       hsa-mir-101-2
hsa-miR-101-3p 7123
                       hsa-mir-101-2
hsa-miR-103a-3p 52629
                       hsa-mir-103a-1
```





#### (DESeq, EdgeR, SAMSeq)



sRNAMapper	Usa: FastQC, Bowtie or BWA
	Anota: tRNA, lincRNA, mt_tRNA, miRNA, rRNA, snRNA, snoRNA, and piRNA
CompaRNA	Faz Expressão Diferencial usando: DESeq, EdgeR, SAMSeq
ncRNAPredictor	Usa o Mirdeep2 para encontrar novos ncRNAs

# Preparando os dados iniciais:

mkdir rna2

cd rna2

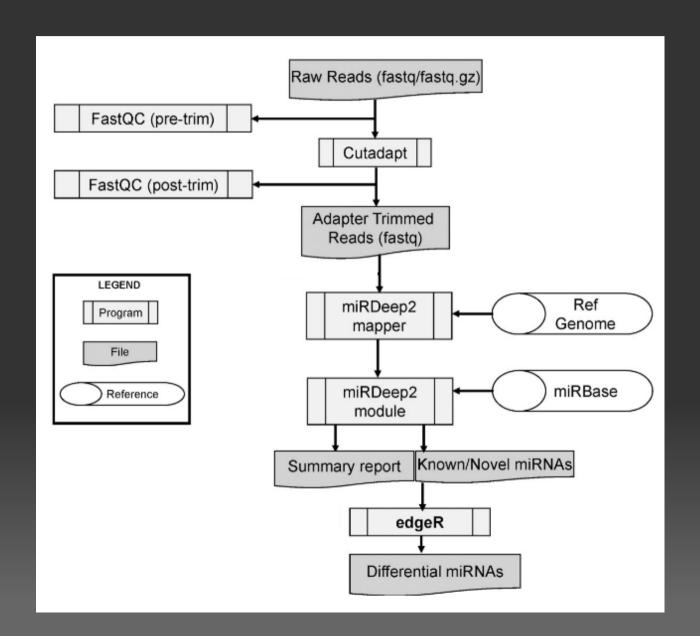
```
In -s /home/treinamento/NGS/RNAseq/sample_data/SRR326279_R1.fastq .
```

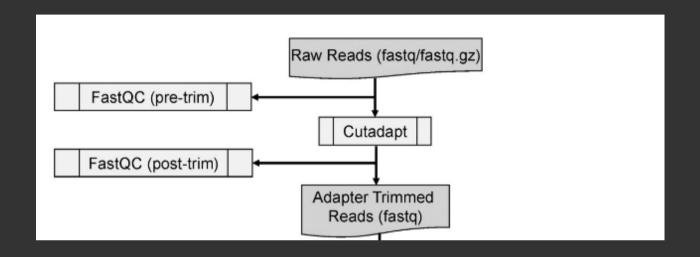
In -s /home/treinamento/NGS/RNAseq/sample\_data/SRR326280\_R1.fastq .

In -s /home/treinamento/NGS/RNAseq/sample\_data/SRR326281\_R1.fastq .

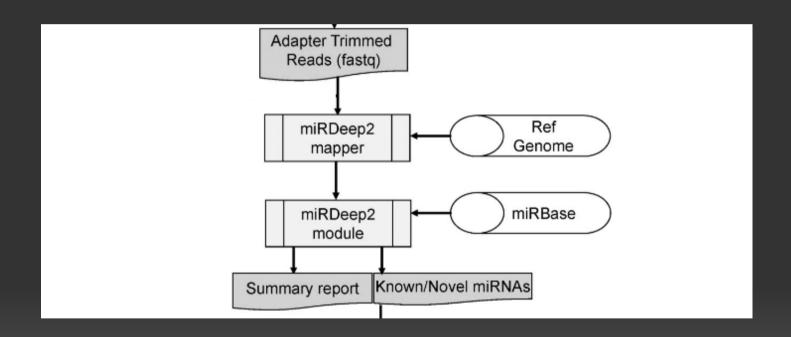
In -s /home/treinamento/NGS/RNAseq/sample\_data/SRR326282\_R1.fastq .

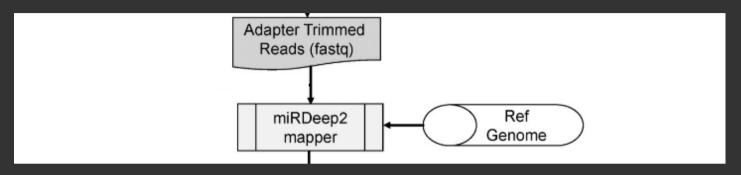
ln -s /home/treinamento/NGS/RNAseq/small\_ref/ .





cutadapt -b AATCTCGTATGCCGTCTTCTGCTTGC -O 3 -m 17 -f fastq SRR326279\_R1.fastq > SRR326279\_R1.ct.fastq





For instance, a typical mapper.pl command might look something like the following:

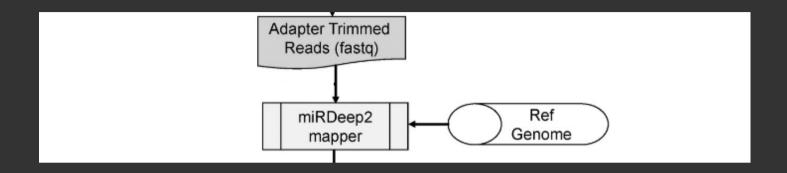
```
mapper.pl trimmed_cutadapt.fastq -e -p reference-genome -s processed_reads.fa -t
mapped_reads.arf -h -m -i -j
```

#### Where:

- · "-e" input file is FASTQ format
- · "-p" map to reference genome
- · "-s" print processed reads to this file
- · "-t" print reads mapping to this file
- · "-h" parse to fasta format
- · "-m" collapse reads
- "-i" convert RNA to DNA alphabet (to map against the genome)
- "-j" remove all entries that have a sequence that contains letters other than a,c,g,t,u,n,A,C,G,T,U,N

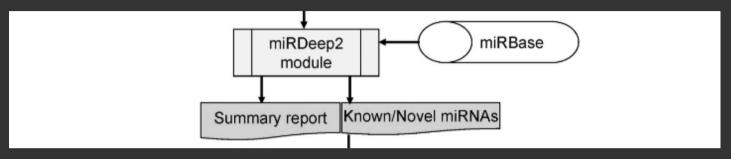
For more command options, use:

mapper.pl --help



## mapper.pl SRR326279\_R1.ct.fastq

- -e
- -p small\_ref/hg19\_chr1
- -s SRR326279.pr.fa
- -t SRR326279.mr.arf
- -h -m -i -j



For instance, a typical miRDeep2.pl command might look something like the following:

```
miRDeep2.pl processed_reads.fa genome.fa mapped_reads.arf mature.fa none
hairpin.fa -t Mouse 2 > report.log
```

#### Where:

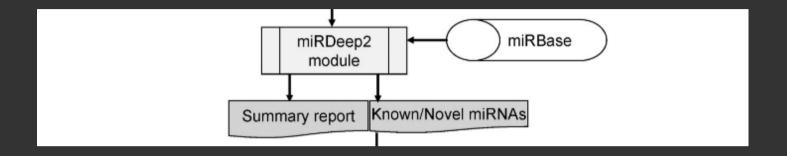
· "-t" species being analyzed

#### output:

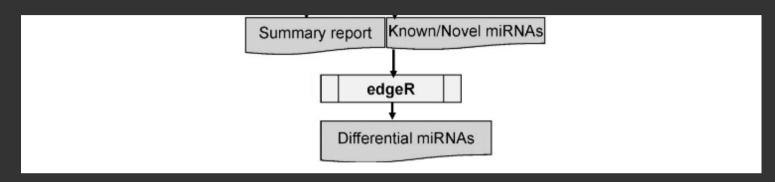
This command will generate a directory with pdfs showing the structures, read signatures and score breakdowns of novel and known miRNAs in the data, an html webpage that links to all results generated (result.html), a copy of the novel and known miRNAs contained in the webpage but in text format which allows easy parsing (result.csv), a copy of the performance survey contained in the webpage but in text format (survey.csv) and a copy of the miRNA read signatures contained in the pdfs but in text format (output.mrd).

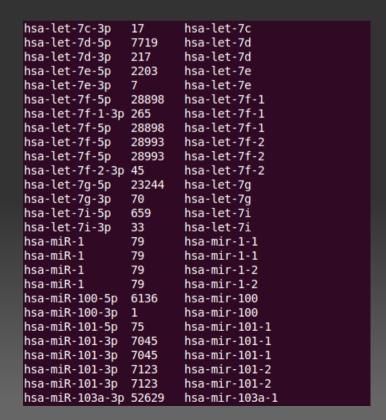
For more command options, use:

```
miRDeep2.pl --help
```



miRDeep2.pl SRR326279.pr.fa
small\_ref/hg19\_chr1.fa
SRR326279.mr.arf
small\_ref/mature.hsa.dna.fa
none
small\_ref/hairpin.hsa.dna.fa
-t Human 2> report.log

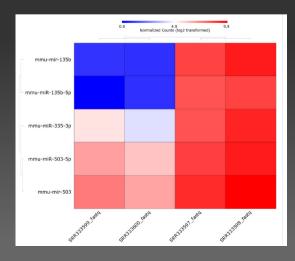








#### (DESeq, EdgeR, SAMSeq)



**CURSO DE CURTA DURAÇÃO - 2017** 

# BIOINFORMÁTICA

BIOME - CENTRO MULTIUSUÁRIO DE BIOINFORMÁTICA - UFRN

Obrigado.

E-mail: jorge@imd.ufrn.br













